

SEMANA 15: MINERÍA DE TEXTOS

GUÍA DE LABORATORIO

Revise junto con el docente el ejemplo de aplicación para que luego pueda resolver el caso de aplicación propuesto.

EJEMPLO DE APLICACIÓN BASE DE DATOS VECTORIALES

1. Aplicaremos los principales conceptos sobre minería de textos haciendo uso de la librería 'chromadb' para implementar una base de datos vectorial en Python (<https://pypi.org/project/chromadb/>).



2. Una vez instaladas, procedemos a importarlas.

```
import chromadb
from sentence_transformers import SentenceTransformer
```

3. Lo que haremos a continuación instanciar una base de datos local y crear una colección (tabla) de nombre "alumnos". De la misma manera, debemos escoger un motor de embeddings para convertir un texto a vector.

```
# Inicializar el motor de vectores local
client = chromadb.Client()

# Crear colección (equivalente a una tabla)
collection = client.create_collection(name="alumnos")
model = SentenceTransformer('all-MiniLM-L6-v2') # Modelo de embedding
```

4. Ahora, vamos a crear unas entradas de texto para convertirlos en embeddings y almacenarlos en la base de datos

```
# Lista de documentos de ejemplo
docs = [
    "Luis es un excelente alumno de ciencia de datos",
    "María tiene interés en la inteligencia artificial",
    "Pedro trabaja en procesamiento de lenguaje natural"
]

# Generar vectores
embeddings = model.encode(docs).tolist()

# Insertar en la colección
collection.add(
    documents=docs,
    embeddings=embeddings,
    ids=["1", "2", "3"]
)
```

5. Ahora, procederemos a colocar un prompt cualquiera y haremos una selección hacia nuestra base de datos vectorial.

```
query = "¿Quién es un alumno sobresaliente?"

query_embedding = model.encode([query]).tolist()

# Buscar los 2 más cercanos
results = collection.query(
    query_embeddings=query_embedding,
    n_results=2
)

print(results['documents'])
```

[['Pedro trabaja en procesamiento de lenguaje natural', 'Luis es un excelente alumno de ciencia de datos']]

6. Finalmente, vamos a visualizar como el modelo convirtió nuestro texto en vectores

```
data = collection.get(include=["embeddings", "documents"])

for doc, id_, emb in zip(data['documents'], data['ids'], data['embeddings']):
    print(f"ID: {id_}")
    print(f"Documento: {doc}")
    print(f"Embedding (primeras 5 dimensiones): {emb[:5]}")
    print("-" * 30)
```

ID: 1
 Documento: Luis es un excelente alumno de ciencia de datos
 Embedding (primeras 5 dimensiones): [-0.0515781 0.07000642 -0.04834177 -0.05982044 -0.01550355]

 ID: 2
 Documento: María tiene interés en la inteligencia artificial
 Embedding (primeras 5 dimensiones): [-0.03857211 -0.01005658 0.00841351 -0.03409148 -0.09196933]

 ID: 3
 Documento: Pedro trabaja en procesamiento de lenguaje natural
 Embedding (primeras 5 dimensiones): [0.04198885 0.0491558 -0.02113147 0.01458174 -0.09477768]

7. Si quieres visualizar lo que almacena una base de datos vectorial, realizar la siguiente acción

```
[7] data = collection.get()  
    print(data)
```

```
⇒ {'ids': ['1', '2', '3'], 'embeddings': None, 'documents':
```

Ahora que ya sabe lo básico, desarrolle lo siguiente:

Cree una base de datos vectorial llamado “Tecsup” y guarde información personal suya y de sus compañeros y luego cree un prompt para poder capturar las respuestas en base a lo guardado.

Luego, utilice la misma solución pero con otro motor de embedding y compare sus respuestas.