



Minería de Datos

Tema de la sesión: Minería de textos

Carrera: Big Data y Ciencia de Datos C28

Capacidades Terminales

Aplica la minería en datos no estructurados como textos.

Contenido

- Minería de textos

Motivación



Revisa el enlace <https://www.youtube.com/watch?v=CMrHM8a3hqw> y responde a las preguntas planteadas por el docente.

Minería de textos

Es el conjunto de **procesos necesarios para transformar documentos o recursos de texto no estructurados** en información significativa y estructurada. La información estructurada puede utilizarse para **descubrir patrones ocultos y predecir resultados futuros** utilizando una combinación de técnicas estadísticas, lingüísticas y de reconocimiento de patrones.


La **tarea de minería más habitual** sobre estos datos es la categorización, la clasificación y el agrupamiento de los textos. Podemos decir que la **categorización** es la tarea que identifica las categorías, temas, materias o conceptos presentes en los textos, mientras que la **clasificación** es la tarea de asignar una clase o categoría a cada documento.




Procesamiento de lenguaje natural

Como sabemos, la minería de textos consiste en transformar un texto no estructurado en datos estructurados para proceder posteriormente al análisis. Esa práctica se basa en la tecnología del **procesamiento de lenguaje natural (NLP)**.

Este último es una rama de la inteligencia artificial que **ayuda a las computadoras a entender, interpretar y manipular el lenguaje humano**. NLP toma elementos prestados de muchas disciplinas, incluyendo la **ciencia de la computación** y la **lingüística computacional**, en su afán por cerrar la brecha entre la comunicación humana y el entendimiento de las computadoras.



Pasos de la minería de textos



Pasos de la minería de textos

Paso	Descripción
Recopilación	Se recopilan los documentos de texto, que están presentes en varios formatos. El documento puede estar en formato PDF, WORD, HTML, DOC, CSS, etc.
Preprocesamiento	Se procesa el documento de entrada dado para eliminar redundancias, inconsistencias, palabras independientes, derivación y se preparan los archivos para el siguiente paso, y las etapas implementadas son las siguientes: <i>tokenization</i> , <i>remover palabras stop</i> , <i>lemmatization</i> y <i>stemming</i> .


Pasos de la minería de textos

Paso	Descripción
Indexación	La recuperación de información crea y almacena un índice de elementos de datos, su ubicación y sus metadatos. Esto proporciona un acceso rápido a los datos almacenados.
Minería	En este proceso, el proceso de minería de datos convencional se combina con el proceso de minería de texto. Una base de datos estructurada facilita las técnicas clásicas de minería de datos que resultaron de una etapa anterior.
Análisis	Este paso produce algunos resultados sin procesar, que luego se deben investigar y evaluar para convertirlos en el resultado deseado.

Bag of words

Es un modelo que se usa principalmente como una **herramienta de generación de atributos o características a partir de un texto**. Después de transformar el texto en una “bolsa de palabras”, podemos calcular varias medidas para caracterizarlo. El tipo más común de características, o características calculadas, a partir del modelo de **bag of words**, es la **frecuencia de los términos**, es decir, la cantidad de veces que aparece un término en el texto.


Para construir el *bag of words* se debe considerar los siguientes procesos: **tokenization**, **remover palabras stop**, **stemming**, **lemmatization**, entre otros.



Tokenization

En esta etapa, el documento dado **se trata como una cadena y se reconoce una sola palabra en el documento**, es decir, la cadena del documento dado se divide en una unidad o ***token***. Esos *tokens* se usan después en los modelos para el clustering de texto o las tareas que buscan asociar documentos.

Básicamente, se trata de **trasladar toda la información de los textos a lenguaje de programación**. De esta manera, se podrán realizar los procesos de minería de datos haciéndose imprescindible, contar con conocimientos en el manejo de algún lenguaje de programación.



Remove palabras *stop*

Algunas palabras aparecen con tanta frecuencia que **no requieren etiquetado tan a fondo como sustantivos, verbos y modificadores**. Llamamos a estas palabras ***stop***, y se pueden filtrar desde el texto que se va a procesar.


Por tanto, esta etapa consiste en **remover las palabras más comunes del idioma** (*a, an, and, of, to, the*, entre otros) ya que aparecen en todos los documentos y no aportan información valiosa para distinguirlos.

When was **the** first computer invented?
How do I install **a** hard disk drive?
How do I use Adobe Photoshop?
Where can I learn **more about** computers?
How to download **a** video **from** YouTube?
What is **a** special character?
How do I clear **my** Internet browser history?
How do you split **the** screen **in** Windows?
How do I remove **the** keys **on a** keyboard?
How do I install **a** hard disk drive?

Stemming

A menudo, al buscar texto para una palabra clave determinada, ayuda mucho si la **búsqueda devuelve variaciones de la palabra**. Por ejemplo, la búsqueda de *boat* también podría devolver *boats* y *boating*. Aquí, *boat* sería el tallo para *boat*, *boater*, *boating* o *boats*.


Stemming es un método sencillo para catalogar palabras relacionadas; esencialmente **corta las letras desde el final hasta que se alcanza el tallo**. Esto funciona bastante bien en la mayoría de los casos, pero desafortunadamente **el inglés tiene muchas excepciones donde se requiere un proceso más sofisticado**.



Lemmatization

En contraste con el *stemming*, la **lemmatization** mira más allá de la reducción de palabras, y **considera el vocabulario completo de un idioma para aplicar un análisis morfológico a las palabras**. El lema de *was* es *be* y el lema de *mice* es *mouse*. Además, el lema de *meeting* podría ser *meet* o *meeting* dependiendo de su uso en una frase.

Se debe tener en cuenta que la *lemmatization* no reduce las palabras a su sinónimo más básico, es decir, **enorme** no se convierte en **grande** y el **automóvil** no se convierte en **coche**.



Stemming vs. Lemmatization

Palabra	Stemming	Lemmatization
<i>information</i>	<i>inform</i>	<i>information</i>
<i>informative</i>	<i>inform</i>	<i>informative</i>
<i>computers</i>	<i>comput</i>	<i>computer</i>
<i>feet</i>	<i>feet</i>	<i>foot</i>

Tareas de la minería de textos



Aplicaciones de la minería de textos

Las herramientas y técnicas de minería de textos se están implementando en una variedad de industrias y áreas en la actualidad como, por ejemplo: académica, atención médica, organizaciones, plataformas de redes sociales, entre otras.


- **Servicio de atención al cliente:** Permite clasificar automáticamente las consultas pudiendo priorizarse por urgencia, así como analizar los comentarios y opiniones de los clientes sobre los productos.
- **Gestión del riesgo:** Permite a las organizaciones mantenerse al día con las tendencias actuales del mercado, obtener la información correcta en el momento correcto e identificar los riesgos potenciales de manera oportuna.
- **Mantenimiento:** Ofrece una visión de conjunto completa de la actividad y del funcionamiento de los equipos y máquinas industriales pudiendo mostrar sobre los motivos y las tendencias que sugieren la aparición de un problema.
- **Salud:** El *clustering* de información permite extraer información a partir de libros de medicina de manera automatizada lo cual permite ganar tiempo.
- **Ciberseguridad:** Puede detectar y filtrar *spam* automáticamente en los buzones de correo electrónico de modo que los hackers ya no pueden usar el método del spam para piratear sistemas informáticos.

Ventajas y desventajas de la minería de textos

Ventajas	Desventajas
Permite analizar grandes volúmenes de datos no estructurados.	La aplicación de esta en conjuntos de datos de la web y que son de naturaleza privada, puede generar preocupaciones éticas.
Como consecuencia de lo anterior, se obtiene una ganancia en productividad.	Las empresas pueden realizar minería de textos para un propósito, pero podrían usar los datos para otro propósito, no declarado o no revelado.
Se pueden hacer análisis en tiempo real, lo cual permite intervenir de manera inmediata en caso de detección de problemas.	-

Ejemplos y/o actividades para afianzar lo aprendido


- Realice un informe sobre librerías de Python para minería de textos:
 - ✓ Una descripción de cuatro de estas librerías.
 - ✓ Las funciones o métodos más importantes de estas junto con su utilidad.
 - ✓ Las referencias y/o fuentes en formato APA de donde se extrajo la información (mínimo 4).



Utilice el formato que se encuentra en el apartado de Tareas de Canvas.

Conclusiones

- Se definió la minería de textos juntos con los pasos que se deben seguir para llevar a cabo esta, así como el *bag of words* y sus procesos (*tokenization*, *remover palabras stop*, *stemming*, *lemmatization*).
- Se definieron algunas aplicaciones de la minería de textos al igual que sus ventajas y desventajas.



Referencias Bibliográficas

- Berry, M. & Linoff, G. (2004). *Data Mining Techniques* (2.^a edición). USA. Wiley Publishing, Inc.
- Han, J.; Kamber, M. & Pei, J. (2001). *Data Mining: Concepts and Techniques* (3.^a edición). USA. Elsevier, Inc.
- Hernández, J.; Ramírez, J. & Ferri, C. (2004). *Introducción a la minería de datos*. España. Pearson Educación, S. A.



TECNOLOGÍA
CON SENTIDO